



PROPUESTA DE ALCANCE Y ESTIMACIÓN TÉCNICA

Sistema de Llamadas de Voz con Inteligencia Artificial

Integración ElevenLabs · Deepgram · Twilio/Telnyx — Propuesta técnica y estimación de alcance

PREPARADO PARA
Campus Land SAS BIC

PRESENTADO POR
FullService Campuslands

FECHA
Julio 2026

MÓDULO / FUNCIONALIDAD	DETALLE TÉCNICO	VALOR (COP)
M0. GESTIÓN Y ESTRUCTURA TRANSVERSAL DEL PROYECTO <i>Fases y costos transversales aplicables a todo el proyecto: liderazgo, arquitectura, UX base, implementación y estructura del agente IA.</i>		\$ 11.247.846
• Estructura del proyecto	Setup inicial, liderazgo/arquitectura y coordinación Scrum del proyecto completo.	\$ 6.133.651
• UX y esquema del proyecto	Diseño UX/UI base aplicable a los módulos con interfaz (dashboard de métricas).	\$ 1.259.452
• Implementación y entrega del sistema	Despliegue, entrega y capacitación general del sistema.	\$ 2.020.764
• Estructura del agente IA	Scaffolding base del agente conversacional de IA.	\$ 1.833.980
M1. ARQUITECTURA, POC Y SETUP <i>Infraestructura base, cuentas en proveedores, número activo en Twilio y primera llamada end-to-end (sin LLM). Semanas 1–3.</i>		\$ 5.283.729
• Infraestructura base y entornos	Provisión de instancias en AWS/GCP/Digital Ocean (mínimo 2), entornos dev/staging/prod, repositorio y metodología Scrum de 2 semanas.	\$ 1.937.565
• Alta de cuentas en proveedores	Creación de cuentas en Twilio, Deepgram, ElevenLabs y proveedor de LLM (Anthropic / OpenAI).	\$ 202.076
• Número telefónico activo en Twilio	Provisión de número local +57 en Twilio, configuración de SIP Trunk y Media Streams (WebSocket) para el canal PSTN.	\$ 882.023
• Webhook de llamadas	Servicio Python/FastAPI que recibe eventos de Twilio/Telnyx (inicio, fin, estado) y gestiona el ciclo de vida de la llamada.	\$ 1.176.031
• Primera llamada end-to-end (sin LLM)	Validación del flujo llamante → Twilio/Telnyx → orquestador → retransmisión de audio, sin integración de STT/LLM/TTS aún.	\$ 1.086.033
M2. PIPELINE DE VOZ BÁSICO <i>STT con Deepgram, TTS con ElevenLabs y flujo completo STT→TTS sin LLM, con latencia medida. Semanas 4–7.</i>		\$ 5.147.111

MÓDULO / FUNCIONALIDAD	DETALLE TÉCNICO	VALOR (COP)
• Media Stream Handler	Servicio Python/asyncio + WebSocket que recibe el stream de audio en tiempo real desde el proveedor de telefonía y reenvía los chunks al STT.	\$ 1.470.039
• STT Service — Deepgram Nova 2	Integración con el SDK de Deepgram, streaming por WebSocket, idioma es-419, endpointing automático; latencia objetivo ~200ms.	\$ 1.634.526
• TTS Service — ElevenLabs	Integración con SDK de ElevenLabs + WebSocket, streaming de audio PCM chunk a chunk con voz personalizada; latencia de primera respuesta 200–400ms.	\$ 1.634.526
• Medición de latencia end-to-end	Instrumentación del pipeline STT→TTS para validar el objetivo de latencia extremo-a-extremo menor a 1.5 segundos por turno conversacional.	\$ 408.021
M3. INTEGRACIÓN LLM Y CONTEXTO <i>LLM integrado, manejo de contexto conversacional, prompts base por tipo de agente y detección de barge-in. Semanas 8–12.</i>		\$ 6.573.070
• LLM Service	Integración con Anthropic SDK / OpenAI SDK (Claude Sonnet / GPT-4o); mantiene el historial de conversación, construye el prompt con contexto y retorna la respuesta en streaming (SSE).	\$ 1.963.500
• Coordinación del pipeline STT → LLM → TTS	Buffering inteligente en el orquestador para minimizar la latencia total acumulada entre las tres capas.	\$ 1.634.526
• Barge-in detection	Detección de cuando el usuario interrumpe la respuesta del agente, deteniendo el TTS en curso de forma inmediata.	\$ 1.176.031
• End-of-turn detection	Determinación de cuándo el usuario terminó de hablar, combinando silencio y endpointing de Deepgram.	\$ 882.023
• Prompts base por tipo de agente	System prompt configurable por agente dentro del LLM Service, según el caso de uso (atención, cobranza, reservas, etc.).	\$ 916.990

MÓDULO / FUNCIONALIDAD	DETALLE TÉCNICO	VALOR (COP)
M4. ORQUESTADOR ROBUSTO <i>Manejo de errores, reconexiones, timeouts, logging estructurado, gestión de estado en Redis y pruebas de carga. Semanas 13–16.</i>		\$ 5.649.126
• Call Orchestrator (FastAPI + asyncio)	Servicio central que coordina el flujo completo de la llamada: apertura y cierre de conexiones WebSocket, reconexiones, silencio, timeouts y errores de cada capa.	\$ 1.764.046
• Manejo de errores y recuperación	Los fallos de red en cualquier capa no deben colapsar la llamada; el sistema debe recuperarse o escalar a un agente humano.	\$ 1.584.051
• Conversation State Manager (Redis)	Almacenamiento en Redis del estado de cada llamada activa (turno actual, historial, variables de contexto, timeouts) con TTL ligado a la duración de la llamada.	\$ 989.991
• Logging estructurado	Registro de cada evento relevante (transcripción, respuesta del LLM, latencias) para análisis posterior.	\$ 494.996
• Pruebas de carga y resiliencia	Validación del orquestador bajo condiciones de fallo parcial, asegurando que el sistema no presente caída total.	\$ 816.041
M5. FEATURES AVANZADOS <i>Llamadas salientes, transferencia a humano, voz clonada, configuración multi-agente y dashboard de métricas. Semanas 17–20.</i>		\$ 9.310.532
• Outbound Call Service	Integración con la API REST de Twilio/Telnyx para iniciar llamadas salientes programáticamente (campañas, recordatorios, cobranzas).	\$ 882.023
• Transferencia a humano (modo híbrido)	El agente IA maneja el inicio de la conversación y transfiere la llamada a un humano cuando el caso lo requiere (escalamiento).	\$ 1.176.031
• Voz clonada	Uso del tier Professional de ElevenLabs para generar una voz personalizada del agente.	\$ 458.495

MÓDULO / FUNCIONALIDAD	DETALLE TÉCNICO	VALOR (COP)
• Configuración de agente por cliente	Cada cliente puede configurar su propio agente (voz, prompt, comportamiento) de acuerdo con su necesidad específica.	\$ 1.340.518
• Admin & Monitoring API	Servicio FastAPI + PostgreSQL con endpoints para gestionar configuraciones de agentes, voces y prompts, y ver métricas por llamada.	\$ 1.484.987
• Dashboard de métricas	Panel en React + Recharts para visualizar llamadas activas, duración promedio, tasas de éxito, transcripciones y logs.	\$ 2.308.995
• Almacenamiento de llamadas en base de datos	Historial de llamadas y transcripciones persistido en PostgreSQL.	\$ 742.493
• Identificación de palabras clave	Extracción de palabras clave por llamada a partir de las transcripciones almacenadas, disponible en el dashboard.	\$ 916.990
M6. PROTOTIPO FINAL Y QA <i>Pruebas end-to-end, optimización de latencia, demo funcional con caso de uso real y documentación técnica. Semanas 21–24.</i>		\$ 3.954.305
• Pruebas E2E	Validación end-to-end del flujo completo de llamada bajo el caso de uso piloto definido (cobranza, atención al cliente, PQRS, reservas, etc.).	\$ 1.224.062
• Optimización de latencia	Ajuste de buffers y pre-warm de conexiones para sostener el objetivo de latencia menor a 1.5 segundos por turno en escenarios reales.	\$ 882.023
• Demo funcional entregable	Demostración con caso de uso real y métricas de desempeño documentadas para el cliente final.	\$ 404.153
• Documentación técnica	Documentación de la arquitectura, integraciones y decisiones técnicas tomadas durante el proyecto.	\$ 1.150.060
• Consentimiento de grabación	Inclusión de aviso de consentimiento de grabación al inicio de la llamada, conforme a la Ley 1581 y regulación SIC en Colombia.	\$ 294.008

MÓDULO / FUNCIONALIDAD	DETALLE TÉCNICO	VALOR (COP)
TOTAL		\$ 47.165.719